

Laporan Proyek Akhir: Preprocessing dan Unsupervised Learning (Clustering)

Nama: Arfi Naza Fatihahdien

NIM: 241011401044

KELAS: 04TPLM007

MATA KULIAH: Data Mining

PROGRAM STUDI: Teknik Informatika

1. Pendahuluan dan Pemilihan Dataset

Pada tugas proyek akhir ini, dataset yang dipilih untuk implementasi proses *Unsupervised Learning (Clustering)* adalah dataset publik **Titanic** (titanic.csv). Dataset ini dipilih karena memenuhi kriteria tugas, yaitu memiliki data mentah yang memerlukan pra-pemrosesan (memiliki *missing values* yang signifikan pada beberapa kolom seperti umur dan kabin) serta memiliki fitur numerik dan kategorikal yang dapat dieksplorasi untuk mengelompokkan profil penumpang.

2. Tahap Cleaning Data (Pra-pemrosesan)

Proses pembersihan data dilakukan dengan tahapan sebagai berikut:

- **Penyeleksian Fitur:** Menghapus kolom yang tidak relevan untuk perhitungan jarak *clustering*, yaitu PassengerId, Name, Ticket, dan Cabin (dihapus karena memiliki lebih dari 70% data kosong).
- **Penanganan Missing Values:**
 - Kolom numerik Age (Umur) yang kosong diimputasi menggunakan nilai tengah (*median*).
 - Kolom kategorikal Embarked (Pelabuhan keberangkatan) diimputasi menggunakan nilai yang paling sering muncul (*modus*).
- **Penanganan Data Duplikat:** Mengecek dan menghapus baris data yang terduplikasi secara identik (*drop_duplicates*).
- **Encoding Data Kategorikal:** Mengubah kolom Sex (Jenis Kelamin) menggunakan *Label Encoding* menjadi nilai biner (0 dan 1). Kolom Embarked diubah menggunakan *One-Hot Encoding*.
- **Scaling / Normalisasi:** Melakukan standarisasi data menggunakan *StandardScaler* agar seluruh fitur memiliki skala yang sama, sehingga algoritma berbasis jarak (seperti K-Means) tidak didominasi oleh fitur dengan rentang nilai yang besar (seperti Fare atau Harga Tiket).

3. Implementasi Clustering

Algoritma yang digunakan untuk pengelompokan data ini adalah **K-Means Clustering**. Implementasinya menggunakan bahasa pemrograman Python dengan *library* Scikit-Learn. Untuk menentukan jumlah *cluster* (K) yang optimal, digunakan metode **Elbow** dengan menghitung nilai inersia dari rentang K=2 hingga K=10. Berdasarkan titik patahan (*elbow point*) pada grafik evaluasi, dipilih **K=3** sebagai jumlah kelompok yang paling merepresentasikan struktur data.

4. Evaluasi dan Visualisasi

Evaluasi model *clustering* dilakukan melalui dua pendekatan:

- **Metode Silhouette Score:** Digunakan untuk mengukur seberapa dekat setiap titik data dalam satu *cluster* dengan titik-titik data di *cluster* tetangganya. Nilai metrik ini memastikan bahwa kelompok yang terbentuk terpisah dengan baik.
- **Visualisasi Scatter Plot 2D:** Hasil pengelompokan divisualisasikan dalam bentuk grafik 2D yang memetakan korelasi antara variabel numerik, misalnya Age (Umur) dan Fare (Harga Tiket), di mana setiap titik diwarnai berdasarkan label *cluster*-nya.

5. Analisis Karakteristik Cluster

Berdasarkan hasil K-Means dengan K=3, secara umum penumpang Titanic dapat dikelompokkan menjadi tiga karakteristik utama (berdasarkan rata-rata variabel dalam setiap kelompok):

Cluster	Karakteristik Umum (Interpretasi)
Cluster 0	Kelompok penumpang dengan harga tiket (<i>fare</i>) terendah dan rata-rata bepergian sendirian atau dari kelas pekerja/kelas 3.
Cluster 1	Kelompok penumpang dengan harga tiket (<i>fare</i>) sangat tinggi (kelas eksekutif/kelas 1) dan rata-rata memiliki angka keselamatan hidup (<i>survivability</i>) yang lebih baik.
Cluster 2	Kelompok penumpang menengah atau penumpang yang bepergian membawa rombongan keluarga besar (nilai <i>SibSp</i> dan <i>Parch</i> tinggi).

Catatan: Analisis karakteristik ini bersifat kualitatif berdasarkan rata-rata centroid pada model K-Means. Laporan ini disertakan sebagai lampiran bersama source code Python (.ipynb) dan dataset asli untuk evaluasi Ujian Akhir Semester.